

Módulo 5

Inteligência Artificial

Aula 5

Agenda

- **Introdução**
- **Processos Estocásticos**
- **Exemplos de Processos Estocásticos com Python**
- **Métricas de Desempenho: Matriz de Confusão e Exemplo em Python**
- **Outras Métricas de Desempenho**

Introdução

Determinístico x Estocástico

- Determinístico

Um processo determinístico se caracteriza por não apresentar nenhum tipo de aleatoriedade. Ao se conhecer as entradas é possível saber exatamente qual a saída. Independe do número de vezes que o processo ocorre a saída sempre será a mesma.

Exemplo: Converter Celsius para Kelvin.

- Estocástico

Um processo estocástica é caracterizado a partir de eventos que envolvem aleatoriedade ou incerteza, **apresentando uma ou mais variáveis aleatórias.**

Exemplo: Jogar uma Moeda.

Introdução

Determinístico x Estocástico

- Calcular a área de um apartamento?
Estocástico ☐ Determinístico ☐

Introdução

Determinístico x Estocástico

- Calcular a área de um apartamento?
Estocástico ☐ Determinístico ☒
- Sortear um número entre 0 - 100?
Estocástico ☐ Determinístico ☐

Introdução

Determinístico x Estocástico

- Calcular a área de um apartamento?
Estocástico ☐ Determinístico ☒
- Sortear um número entre 0 - 100?
Estocástico ☒ Determinístico ☐
- Jogar um dado para o alto e cair o número 4 com a face para cima?
Estocástico ☐ Determinístico ☐

Introdução

Determinístico x Estocástico

- Calcular a área de um apartamento?
Estocástico ☐ Determinístico ☒
- Sortear um número entre 0 - 100?
Estocástico ☒ Determinístico ☐
- Jogar um dado para o alto e cair o número 4 com a face para cima?
Estocástico ☒ Determinístico ☐

Introdução

Processos Estocásticos

Todo o Processo que pode ser modelado como um problema de probabilidade é considerado como um **Processo Estocástico**.

Introdução

Processos Estocásticos na Indústria

- Grau de desgaste de uma ferramenta.
- Número de produtos defeituosos em uma linha de montagem.
- Quantidade de unidades de determinado produto vendidas por dia.
- Outros...?

Algoritmos Estocásticos

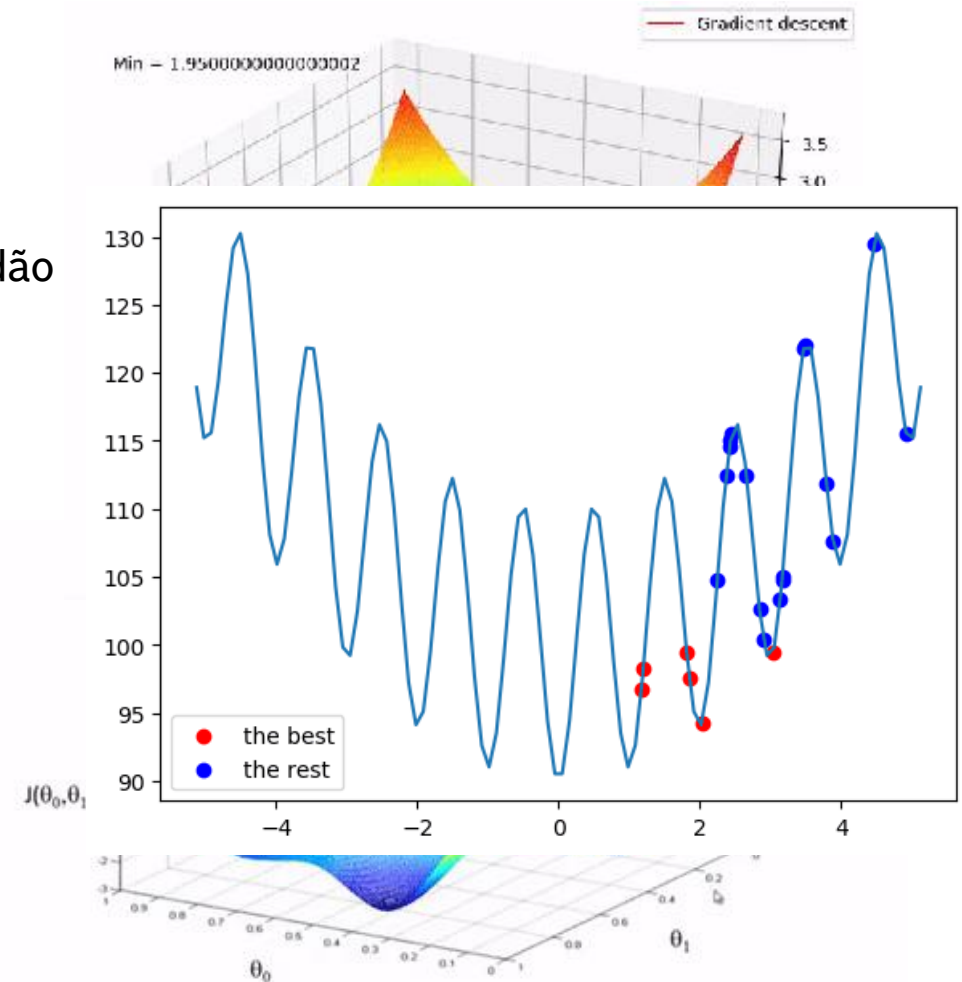
Algoritmos Estocásticos

Definição

- **Algoritmos Estocásticos**, diferente de algoritmos determinísticos, utilizam variáveis aleatórias para obter um resultado (aproximação do resultado). Portanto, mesmo conhecendo suas entradas não é possível dizer com exatidão qual serão suas saídas.
- Ao empregar variáveis aleatórias, temos que os algoritmos estocásticos apresentam maior flexibilidade em várias aplicações, atingindo resultados que os algoritmos determinísticos não conseguiriam ou não seriam viáveis.
- São muito utilizados em problemas complexos de muitas variáveis onde os métodos analíticos são inefficientes ou limitados.

Ex: simulação, otimização, etc...

- Os processos estocásticos geralmente são chamados por métodos de Monte Carlo (MC) ou Monte Carlo Cadeia de Markov (MCMC).



Algoritmos Estocásticos

Monte Carlo (MC) ou Monte Carlo Cadeia de Markov (MCMC)

- Foi proposto em 1946 pelo físico Stanislaw Ulam e desenvolvido em conjunto com o físico-matemático John Von Neumann e outros colegas cientistas durante o projeto Mahattan.
- Inspirado por Ulam numa tentativa de estimar as chances de ganhar no jogo de cartas “Paciência”.
- Foi muito importante para simulações da difusão de nêutrons em ogivas usadas na produção das bombas atômicas desenvolvidas no Projeto Manhattan.
- O **MC** ou **MCMC**, pode ser descrito como método de simulação estatística que utiliza geradores de números aleatórios em cada iteração para desenvolver as simulações.
- Trata-se de um método numérico universal para resolver problemas por meio de amostragem aleatória.

Refs:


http://www2.dbd.puc-rio.br/pergamum/tesesabertas/1012652_2012_cap_3.pdf

<http://www.inf.ufpr.br/pfperoni/archive/MonteCarlo.pdf>

Algoritmos Estocásticos

Monte Carlo – Exemplo 1: Obtendo o valor de Pi

- Podemos calcular o valor de π utilizando números aleatórios?



$$A_c = \pi r^2$$

$$A_q = 4r^2$$

$$P_{chuvac} = \frac{\pi r^2}{4r^2}$$

$$P_{chuvac} = \frac{\pi}{4}$$



$$\pi = 4 \times P_{chuvac}$$

$$\pi = 4 \times \frac{N_{gotas\ círculo}}{N_{gotas\ quadrado}}$$

Algoritmos Estocásticos

Monte Carlo – Exemplo 1: Obtendo o valor de Pi

Como estimar o valor de π usando números aleatórios?



Algoritmos Estocásticos

Monte Carlo – Exemplo 2: Determinístico vs. Estocástico

Jogue uma moeda 10 vezes. Qual a probabilidade de obter mais que 3 caras?

Resolução Analítica: Distribuição Binomial.

Resolução via Método Estocástico: Monte Carlo.

Métricas de Desempenho

Métricas de Desempenho

Definição

- Consiste no conjunto de métricas utilizadas para avaliar o desempenho de um algoritmo.
- A avaliação de desempenho é uma etapa muito importante, dependendo do problema e do algoritmo utilizado pode ser uma tarefa difícil, e deve ser feita tomando o devido cuidado.
- É recomendado, em problemas mais complexos (a até mesmo nos mais simples), a utilização de mais de uma métrica de desempenho, a fim de ter um resultado mais fiel ao comportamento do algoritmo (ou algoritmos) em questão.
- Métricas diferentes podem representar noções diferentes para o mesmo resultado, a fim de, facilitar o processo de tomada de decisão.

Métricas de Desempenho

Definição

As métricas mais comuns utilizadas na avaliação e comparação de algoritmos:


- Métricas de Erro.
- Custo Computacional.
- Convergência.

Métricas de Desempenho

Métricas de Erro

As métricas de erro consistem na avaliação do resultado final do algoritmo em relação a uma dada solução, e a mesma deve ser selecionada de acordo com a característica do problema.


Problemas de Classificação



Problemas de Regressão



Detecção de Objetos



Métricas de Desempenho

Métricas de Erro

As métricas de erro consistem na avaliação do resultado final do algoritmo em relação a uma dada solução, e a mesma deve ser selecionada de acordo com a característica do problema.

Problemas de Classificação

- Matriz de Confusão
- Acurácia
- Precisão
- Recall
- F1

Problemas de Regressão

- R^2
- MSE/RMSE
- MAE

Detecção de Objetos

- MAP

Métricas de Desempenho

Métricas de Erro - Classificação

- **Matriz de Confusão**, é uma matriz que apresenta o número de observações reais e preditas pelo algoritmo.

		Valor Verdadeiro	
		Classe Positiva	Classe Negativa
Valor previsto	Classe Positiva	VP Verdadeiro Positivo	FP Falso Positivo
	Classe Negativa	FN Falso Negativo	VN Verdadeiro Negativo

TP-True Positive ou VP-Verdadeiro Positivo: Classe **Positiva** é classificada como **Positiva**.

FP-False Positive ou Falso Positivo: Classe **Negativa** é classificada como **Positiva**.

FN-False Negative ou Falso Negativo: Classe **Positiva** é classificada como **Negativa**.


TN-True Negative ou VN-Verdadeiro Negativo: Classe **Negativa** é classificada como **Negativa**.

Métricas de Desempenho

Métricas de Erro - Classificação

- **Matriz de Confusão**, é uma matriz que apresenta o número de observações reais e preditas pelo algoritmo.

N = 600		Previsão	
		Yes	No
Real	Yes	50 (TP)	40 (FN)
	No	10 (FP)	500 (TN)



Métricas de Desempenho

Métricas de Erro - Classificação

- **Acurácia** ou taxa de acerto é a métrica mais intuitiva, se resume à razão do número de observações corretamente preditas sob o número do total de observações. É uma ótima métrica para avaliar modelos nos quais os dados possuem classes balanceadas, ou seja o mesmo número de observações por classe.

$$\text{Acurácia} = \frac{TP + TN}{TP + FP + TN + FN}$$

- **Precisão** é a taxa de observações classificadas corretamente como positivas em relação a todas as observações classificadas como positivas. Uma alta precisão se relaciona com uma baixa taxa de falsos positivos (FP).

$$\text{Precisão} = \frac{TP}{TP + FP}$$

Métricas de Desempenho

Métricas de Erro - Classificação

- **Recall** (Sensibilidade) se remete à proporção de observações corretamente classificadas como positivas em relação a todas as observações positivas que poderiam ter sido feitas, ou seja, também levam em consideração observações positivas marcadas como negativas (FN).

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-Score** é a média harmônica entre **Precisão** e **Recall**. Essa métrica leva em consideração ambos falsos negativos e falsos positivos. É uma métrica mais utilizada que acurácia, principalmente se possui dados com classes desbalanceadas, ou seja, quantidades diferentes de observações por classe.

$$F1 = \frac{2 * (\text{Recall} * \text{Precisão})}{\text{Recall} + \text{Precisão}}$$

Métricas de Desempenho

Métricas de Erro - Classificação

Em resumo das métricas de erro de classificação:

- **Acurácia** mede a taxa de acerto do modelo, com classes balanceadas.
- **Precisão** indica a proporção de itens da classe classificados corretamente (TP) entre as observações marcadas da mesma classe (TP + FP).
- **Recall** indica a proporção de itens da classe classificados corretamente (TP) em relação a eles mesmos (TP) mais os itens da classe classificados incorretamente (FN).
- **F1-Score** média harmônica de **Precisão** e **Recall**. Leva em consideração FN e FP. Mais utilizado que **Acurácia** para dados com classes desbalanceadas.

Métricas de Desempenho

Exemplo: Matriz de Confusão

Suponha que você está usando um algoritmo para um aprendizado de máquina que precisa prever se pacientes de uma clínica estão infectados ou não por um vírus. Após treinar seu algoritmo com dados de treino, você escolhe 10 valores de teste e monta a tabela a seguir:

a) A partir da tabela, construa a Matriz de Confusão para o problema;

b) Determine os parâmetros a seguir:

- Recall
- Especificidade
- Acurácia
- Precisão
- F1-Score

Predição	Real
Tem Vírus	Tem vírus
Não tem Vírus	Não tem Vírus
Tem Vírus	Tem Vírus
Tem Vírus	Tem Vírus
Não tem Vírus	Tem Vírus
Tem Vírus	Não tem Vírus
Tem Vírus	Tem Vírus
Tem Vírus	Não tem Vírus
Tem Vírus	Tem Vírus
Tem Vírus	Tem Vírus